

Ienākumu prognozēšana — izglītība un dzimums ASV datos

Adult Census Income | Klasifikācija | Eva Stūrīte | 2026

Problēma un dati

-  Vai izglītība un dzimums ietekmē ienākumus ASV?
-  Dataset: Adult Census Income
 - - 32,561 cilvēki × 15 kolonnas
 - - Target: $\leq 50K$ vai $> 50K$ gadā
 - - Sadalījums: 75.9% / 24.1%

ML Pipeline pieeja

-  Priekšapstrāde:
 - - Izdzēsām ? vērtības (5.6%)
 - - OneHotEncoding kategoriskajām kolonnām
 - - StandardScaler skaitliskajām kolonnām
-  Feature Engineering:
 - - age × education.num → pieredzējis UN izglītots
 - - is_high_education → Bachelors vai augstāk (1/0)
-  Pipeline → novērš data leakage
-  Cross-validation (cv=5) → uzticams rezultāts



Modeļu salīdzinājums

- | Modelis | CV F1 |
- |---|---|
- | Logistic Regression (bāzes) | 0.604 |
- | Random Forest | 0.554 |
- | GradientBoosting | 0.535 |
- | Random Forest + GridSearchCV | 0.573 |
- | Logistic Regression + GridSearchCV | 0.602 |

- 🏆 Uzvarētājs: Logistic Regression
- Vienkāršākais modelis izrādījās labākais!

Rezultāti

- 🏆 Labākais modelis: Logistic Regression
- CV F1 = 0.602 | Precizitāte = 85%
- 📊 Top 3 svarīgākās pazīmes:
 - 1. capital.gain — kapitāla ienākumi
 - 2. sex_Female — dzimums (10. vieta!)
 - 3. education.num — izglītība (18. vieta)
- ⚠️ Kur modelis kļūdās:
 - 599 cilvēki ar >50K netika atpazīti
 - Recall = 0.60 — iemesls: 75%/25% disbalanss



Secinājumi un nākamie soļi

-  Atbilde uz jautājumu:
 - - Jā — izglītība UN dzimums ietekmē ienākumus!
 - - Bet kapitāls un ģimenes statuss ietekmē vairāk — pārsteigums!
-  Modelis:
 - - 85% precizitāte — pieņemams pirmais solis
 - - $F1 = 0.602$ — stabils rezultāts
-  Nākamie soļi:
 - - SMOTE — disbalansa novēršana
 - - XGBoost — spēcīgāks modelis
 - - Dziļāks Feature Engineering